

Video Depth Anything: Reprodução e Avaliação em Vídeos Fora do Domínio de Treinamento

Antonio Lucas da Silva Vale^{*}, Jeanderson da Silva Campos^{*},
Lucas Martins Campos Matos^{*} e Haroldo Gomes Barroso Filho[†]

^{*}Curso de Engenharia da Computação

[†]Coordenação do Curso de Engenharia da Computação

Centro de Ciências Exatas e Tecnologia (CCET)

Universidade Federal do Maranhão (UFMA), São Luís, Maranhão, Brasil

Autor correspondente: lucas.mcm@discente.ufma.br

Resumo—A estimativa de profundidade a partir de vídeo monocular é central em visão computacional, com aplicações em realidade aumentada, robótica e edição de vídeo. Modelos de imagem única como o Depth Anything V2 generalizam bem entre domínios, mas produzem inconsistência temporal, o *flickering*, quando aplicados quadro a quadro. O Video Depth Anything (VDA) resolve isso com uma cabeça de decodificação espaço-temporal leve, treinada com uma perda *Temporal Gradient Matching*, combinada a uma estratégia de inferência por janelas deslizantes que processa vídeos de duração arbitrária sem acumular erro de escala. Este trabalho reproduz a arquitetura e a estratégia de inferência do VDA e o avalia em regime *zero-shot* em dois conjuntos fora do domínio de treinamento original: o TUM RGB-D, com profundidade de referência real, e um vídeo de manifestação cultural brasileira, usado como estudo de caso qualitativo sem profundidade de referência disponível. O VDA é comparado com dois modelos concorrentes avaliados pelos autores originais, DepthCrafter e ChronoDepth, pelas métricas AbsRel, RMSE, δ_1 e TAE. Os resultados mostram desempenho geométrico equivalente entre VDA e DepthCrafter, enquanto o ChronoDepth obtém maior consistência temporal ao custo de menor acurácia geométrica.

I. INTRODUÇÃO

A estimativa de profundidade monocular infere distâncias de cena a partir de uma única câmera, sem sensores especializados. Modelos de base como MiDaS [7] e Depth Anything V2 [2] treinam em grandes conjuntos heterogêneos, reais e sintéticos, produzindo estimativas de profundidade relativa que generalizam entre domínios diversos. Aplicados quadro a quadro a um vídeo, esses modelos geram profundidade inconsistente para a mesma região de cena em quadros consecutivos, fenômeno conhecido como *flickering*.

Duas linhas de trabalho atacam esse problema. A primeira acrescenta módulos de suavização temporal sobre modelos de imagem pré-treinados, como o NVDS [6], que estabiliza predições com uma perda de deformação por fluxo óptico (OPW). A segunda reformula a tarefa como geração condicional via modelos de difusão de vídeo, como DepthCrafter [3] e ChronoDepth [4], condicionando a profundidade a uma janela de quadros ao mesmo tempo. Esses métodos melhoram a consistência temporal, mas herdam da difusão um custo de inferência alto e, na maioria dos casos, um limite rígido no número de quadros processáveis de uma vez.

O Video Depth Anything (VDA) [1], método reproduzido neste trabalho, evita a difusão. Usa uma cabeça espaço-temporal leve treinada com a perda *Temporal Gradient Matching* (TGM), que impõe consistência temporal sem fluxo óptico, combinada a uma estratégia de inferência por janelas ancoradas em quadros-chave que processa vídeos de duração arbitrária com baixa latência.

Este trabalho reproduz a arquitetura e o pipeline de inferência do VDA, sem retreinamento, usando os pesos publicados, e avalia o modelo em regime **zero-shot** em dados fora dos protocolos originais de treinamento e avaliação. O conjunto de dados de avaliação original é substituído por: (i) TUM RGB-D [11], com profundidade de sensor real que viabiliza comparação quantitativa; e (ii) um vídeo do Bumba Meu Boi, manifestação cultural popular do Maranhão, usado como estudo de caso qualitativo em domínio ausente da literatura de estimativa de profundidade, marcado por multidão em movimento, iluminação noturna artificial e trajes com texturas complexas. O VDA é comparado com DepthCrafter e ChronoDepth pelas mesmas métricas do artigo original.

As contribuições deste trabalho são: (i) reprodução da arquitetura, formulação matemática e estratégia de inferência do VDA, validada fora do domínio de treinamento; (ii) avaliação quantitativa zero-shot comparando VDA, DepthCrafter e ChronoDepth em três sequências do TUM RGB-D sob o protocolo de métricas original; e (iii) avaliação qualitativa em vídeo de manifestação cultural brasileira, ilustrando a aplicabilidade do método a um domínio pouco explorado.

O trabalho está organizado da seguinte forma: a Seção II cobre a formulação matemática, a arquitetura e a estratégia de inferência do VDA; a Seção III descreve os conjuntos de dados e o protocolo de avaliação; a Seção IV reporta os resultados quantitativos e qualitativos; a Seção V fecha com conclusões e trabalhos futuros.

II. FUNDAMENTAÇÃO TEÓRICA

A. Formulação do Problema e Perda Invariante a Transformações Afins

O VDA é construído sobre o Depth Anything V2 [2], modelo de profundidade relativa treinado em múltiplos conjuntos heterogêneos. Conjuntos diferentes representam profundidade

em escalas e deslocamentos distintos, por isso o modelo prediz **disparidade** em vez de profundidade absoluta. Para cada pixel, a disparidade é definida como

$$d = \frac{1}{t}, \quad (1)$$

em que t é a profundidade métrica do ponto. Trabalhar no espaço de disparidade normaliza a representação: pontos distantes se aproximam de zero, pontos próximos produzem valores maiores, o que estabiliza o treinamento conjunto em conjuntos heterogêneos.

Para treinar entre conjuntos com escalas distintas, o modelo usa uma perda invariante a transformações afins sobre a imagem completa (HW pixels):

$$\mathcal{L}_l = \frac{1}{HW} \sum_{i=1}^{HW} \rho(d_i^*, d_i), \quad (2)$$

em que d_i^* e d_i são a predição do modelo e a disparidade de referência no pixel i , respectivamente. O termo ρ é o erro absoluto médio invariante a transformações afins:

$$\rho(d_i^*, d_i) = |\hat{d}_i^* - \hat{d}_i|, \quad (3)$$

com $\hat{d}_i^*$ e $\hat{d}_i$ sendo as versões alinhadas por escala e deslocamento da predição e da referência:

$$\hat{d}_i = \frac{d_i - t(d)}{s(d)}, \quad (4)$$

com as funções de alinhamento definidas por

$$t(d) = \text{mediana}(d), \quad s(d) = \frac{1}{HW} \sum_{i=1}^{HW} |d_i - t(d)|. \quad (5)$$

$t(d)$ centraliza a distribuição de disparidade e $s(d)$ normaliza sua dispersão, tornando a comparação entre predição e referência independente da escala e do deslocamento de cada conjunto. Essa formulação, herdada do MiDaS [7], é a base sobre a qual o VDA constrói sua extensão temporal, e corresponde ao termo $\mathcal{L}_{ssi}$ na Equação (9).

B. Arquitetura Espaço-Temporal

O VDA mantém o encoder DINOv2 [8] do Depth Anything V2 **congelado** durante o treinamento; apenas a cabeça de decodificação é atualizada. A entrada, seja um vídeo de N quadros ou uma imagem única ($N=1$), é reorganizada em um tensor $X \in \mathbb{R}^{(B \times N) \times C \times H \times W}$: a dimensão temporal é fundida à dimensão de batch antes do encoder, preservando compatibilidade com o treinamento em imagens estáticas.

A principal mudança estrutural é a *Spatiotemporal Head* (STH), que substitui a cabeça DPT padrão, ilustrada na Figura 1. Em posições selecionadas de baixa resolução espacial na pirâmide de características, camadas temporais são inseridas: cada uma realiza atenção multi-cabeça ao longo do eixo temporal, comparando a mesma posição espacial nos N quadros, seguida de uma rede *feed-forward*, com embeddings posicionais absolutos codificando a posição de cada quadro na janela. Isso permite que a rede compare diretamente a mesma região espacial em quadros distintos, sem o custo quadrático de uma atenção espaço-temporal completa sobre todos os pixels.

C. Temporal Gradient Matching Loss

Modelos anteriores de consistência temporal, como o NVDS [6], assumem que a profundidade em posições correspondentes entre quadros adjacentes, identificadas por fluxo óptico, deve permanecer aproximadamente constante, gerando a perda OPW:

$$\mathcal{L}_{OPW} = \frac{1}{N-1} \sum_{i=2}^N \|p_i - \hat{p}_i\|_1, \quad (6)$$

em que p_i e p_{i+1} são predições de profundidade consecutivas e $\hat{p}_i$ é o mapa p_{i+1} deformado até o quadro i pela transformação de fluxo óptico. Essa suposição falha em cenas com movimento relativo entre câmera e objetos, pois a profundidade de um ponto correspondente pode mudar quando um objeto se aproxima da câmera.

Um passo intermediário substitui a comparação direta de profundidade pela comparação do *erro* entre predição e referência ao longo do tempo, definindo o Erro Estável (SE):

$$\mathcal{L}_{SE} = \frac{1}{N-1} \sum_{i=1}^{N-1} \left\| |\hat{d}_i - d_i| - |\hat{g}_i - g_i| \right\|_1, \quad (7)$$

em que d_i, g_i são a predição e a referência alinhadas por escala e deslocamento (Eq. (4)), e $\hat{d}_i, \hat{g}_i$ são suas versões deformadas pelo fluxo óptico entre quadros consecutivos.

A contribuição central do VDA, a *Temporal Gradient Matching Loss*, remove a dependência do fluxo óptico ao comparar o gradiente temporal de profundidade diretamente, ou seja, a variação de profundidade entre quadros consecutivos nas mesmas coordenadas de imagem, sem correspondência de movimento:

$$\mathcal{L}_{TGM} = \frac{1}{N-1} \sum_{i=1}^{N-1} \left\| |d_{i+1} - d_i| - |g_{i+1} - g_i| \right\|_1. \quad (8)$$

Na prática, o termo é computado apenas onde a variação da referência é pequena ($|g_{i+1} - g_i| < 0,05$), reduzindo a influência de bordas de oclusão e objetos em movimento rápido que poderiam desestabilizar o treinamento.

A perda total combina o termo temporal com a perda invariante a transformações afins da Eq. (2), aplicada quadro a quadro:

$$\mathcal{L}_{total} = \alpha \mathcal{L}_{TGM} + \beta \mathcal{L}_{ssi}, \quad (9)$$

em que α e β balanceiam consistência temporal e qualidade estrutural por quadro.

D. Estratégia de Inferência para Sequências Longas

O modelo treina em janelas curtas de $N=32$ quadros, mas a inferência precisa suportar vídeos de duração arbitrária. O VDA resolve isso em duas etapas, ilustradas na Figura 2.

Janelas ancoradas em quadros-chave. O vídeo é processado em janelas deslizantes com T_o quadros sobrepostos entre janelas consecutivas. Em vez de tratar cada janela de forma independente, uma fração dos quadros de entrada de cada nova janela é substituída pela profundidade já estimada de quadros-chave (T_k) da janela anterior, amostrados a intervalos regulares Δ_k e sempre incluindo o primeiro quadro do vídeo. Isso ancora a escala da nova janela à escala global já estabelecida,




Fig. 1. Visão geral da arquitetura do Video Depth Anything. Figura adaptada de [1].

reduzindo a deriva de escala que se acumula quando cada janela é tratada de forma isolada.

Interpolação na sobreposição. Para evitar transições abruptas nas fronteiras entre janelas, a profundidade nos quadros sobrepostos é combinada por interpolação linear entre as estimativas da janela anterior e da atual:

$$D_{o_i} = D_{o_i}^{prev} \cdot w_i + D_{o_i}^{cur} \cdot (1 - w_i), \quad (10)$$

com o peso w_i decaindo linearmente de 1 a 0 ao longo dos T_o quadros sobrepostos.




Fig. 2. Estratégia de inferência por janelas ancoradas em quadros-chave. Figura adaptada de [1].

III. METODOLOGIA

A. Conjuntos de Dados e Protocolo de Avaliação Zero-Shot

Em substituição aos conjuntos originais do artigo (KITTI, Sintel, ScanNet, NYUv2 e Bonn), dois conjuntos são usados aqui, nenhum deles parte do treinamento de qualquer modelo, caracterizando avaliação **zero-shot**:

TUM RGB-D [11] é amplamente usado em avaliação de SLAM e odometria visual, com profundidade de referência real capturada por sensor RGB-D. Três sequências foram selecionadas: *freiburg1_desk*, *freiburg2_desk* e *freiburg3_long_office_household*, cada uma limitada a 110 quadros associados por proximidade de timestamp entre RGB e profundidade, o mesmo tamanho de janela do protocolo original do DepthCrafter [3].

Bumba Meu Boi Raízes do Maranhão é um vídeo de manifestação cultural popular maranhense, sem profundidade de referência disponível. Serve como estudo de caso qualitativo em domínio ausente da literatura de estimativa de profundidade: multidão em movimento, iluminação noturna artificial e trajes com texturas complexas.

B. Modelos Comparados

O VDA foi reproduzido em sua variante *small* (ViT-S, pesos oficiais) e comparado com dois modelos do artigo original: **DepthCrafter** [3] e **ChronoDepth** [4], ambos baseados na *Stable Video Diffusion* [9]. Um terceiro concorrente, o DepthAnyVideo [5], foi testado mas excluído da comparação quantitativa por exigir memória de GPU superior à disponível.

C. Pré-processamento dos Vídeos e Associação RGB-Profundidade

Os vídeos de entrada foram montados via *ffmpeg* a partir dos quadros RGB e de profundidade associados por proximidade de timestamp, e recodificados no perfil *baseline* do H.264 para compatibilidade com os pipelines de inferência.

D. Conversão de Disparidade e Alinhamento de Escala

Os três modelos predizem disparidade relativa, mas com convenções de normalização distintas. VDA e DepthCrafter seguem a Eq. (1) diretamente, $t^* = 1/d^*$, com o DepthCrafter normalizando d^* em $[0, 1]$ antes da inversão. O ChronoDepth usa a convenção inversa:

$$t^* = \frac{1}{1 - d^*}, \quad (11)$$

identificada empiricamente a partir de valores de AbsRel implausíveis sob a inversão direta.

Cada predição t^* é então alinhada à referência t por razão de medianas, de forma análoga à Eq. (5):

$$\lambda = \frac{\text{mediana}(t)}{\text{mediana}(t^*)}, \quad \hat{t}^* = \lambda \cdot t^*. \quad (12)$$

As métricas são calculadas apenas sobre os pixels válidos, definidos pela máscara M em que referência e predição alinhada estão no intervalo $[0, 1 \text{ m}, 10 \text{ m}]$, faixa compatível com o sensor do TUM RGB-D.

E. Métricas de Avaliação

Seguindo o protocolo do artigo original, com a profundidade convertida e alinhada $\hat{t}^*$ (Eq. (12)) e a máscara de validade M , as seguintes métricas são calculadas por sequência sobre os pixels válidos:

$$\text{AbsRel} = \frac{1}{|M|} \sum_{i \in M} \frac{|\hat{t}_i^* - t_i|}{t_i}, \quad (13)$$

$$\text{RMSE} = \sqrt{\frac{1}{|M|} \sum_{i \in M} (\hat{t}_i^* - t_i)^2}, \quad (14)$$

$$\delta_1 = \frac{1}{|M|} \sum_{i \in M} \mathbb{I} \left[\max \left(\frac{\hat{t}_i^*}{t_i}, \frac{t_i}{\hat{t}_i^*} \right) < 1,25 \right], \quad (15)$$

em que $\mathbb{I}[\cdot]$ é a função indicadora. AbsRel e RMSE penalizam o erro absoluto, com RMSE mais sensível a desvios grandes; δ_1 mede a fração de pixels cuja razão predição/referência fica abaixo de 1,25, tolerando pequenos desvios.

A métrica **TAE** (*Temporal Alignment Error*) não requer profundidade de referência e pode ser calculada inclusive no vídeo do Boi. Segue a mesma estrutura da perda OPW da Eq. (6), mas entre predições consecutivas do modelo, não entre predição e referência:

$$\text{TAE} = \frac{1}{N-1} \sum_{i=1}^{N-1} \|\hat{t}_{i+1}^* - W_{i \rightarrow i+1}(\hat{t}_i^*)\|_1, \quad (16)$$

em que $W_{i \rightarrow i+1}(\cdot)$ deforma a predição do quadro i até as coordenadas do quadro $i+1$ por fluxo óptico. Valores baixos de TAE indicam predições estáveis ao longo do tempo.

F. Ambiente de Execução

Todos os experimentos rodaram no Google Colab com GPU NVIDIA T4 (15 GB). O VDA foi executado a partir do repositório oficial sem alterações na arquitetura ou nos hiperparâmetros de inferência. DepthCrafter e ChronoDepth foram executados a partir de seus respectivos repositórios oficiais com os parâmetros padrão recomendados pelos autores para GPUs com memória limitada.

IV. RESULTADOS E DISCUSSÃO

A. Resultados Quantitativos

A Tabela I reporta os resultados médios nas três sequências do TUM RGB-D para os três modelos, e a Tabela II detalha os resultados por sequência.

TABLE I
RESULTADOS MÉDIOS NO TUM RGB-D

Modelo	AbsRel↓	RMSE↓	δ_1 ↑	TAE↓
VDA (ViT-S)	0,0901	0,4836	0,9464	0,0437
DepthCrafter	0,0886	0,3462	0,9457	0,0382
ChronoDepth	0,1342	0,4866	0,8411	0,0244

VDA e DepthCrafter têm desempenho geométrico quase idêntico: AbsRel e δ_1 diferem em menos de 0,002, com DepthCrafter registrando o menor RMSE médio. O ChronoDepth obtém o menor TAE dos três, indicando maior consistência temporal, ao custo da menor acurácia geométrica.

TABLE II
RESULTADOS POR SEQUÊNCIA NO TUM RGB-D

Sequência	Modelo	AbsRel↓	RMSE↓	δ_1 ↑	TAE↓
freiburg1_desk	VDA	0,1366	0,6960	0,8982	0,0571
	DepthCrafter	0,0914	0,2999	0,9586	0,0385
	ChronoDepth	0,1403	0,5464	0,8748	0,0372
freiburg2_desk	VDA	0,0732	0,4507	0,9599	0,0434
	DepthCrafter	0,1032	0,4202	0,9237	0,0431
	ChronoDepth	0,1779	0,5840	0,7107	0,0189
freiburg3_office	VDA	0,0606	0,3042	0,9812	0,0306
	DepthCrafter	0,0711	0,3185	0,9547	0,0330
	ChronoDepth	0,0843	0,3295	0,9378	0,0170

B. Análise Qualitativa

A Figura 3 compara os três modelos no mesmo formato do artigo original para sequências *in-the-wild* do DAVIS [10]: quadro de entrada seguido do mapa de profundidade colorido de cada modelo. Onde o artigo original seleciona seis vídeos distintos do DAVIS, aqui cada linha corresponde a uma das quatro sequências deste estudo, as três do TUM RGB-D e o vídeo do Bumba Meu Boi, cobrindo os domínios quantitativo e puramente qualitativo.

Em *freiburg1_desk*, VDA e DepthCrafter produzem mapas de profundidade estruturalmente próximos: o monitor separa bem do fundo e a mesa apresenta gradiente suave. O ChronoDepth preserva a mesma estrutura geral, mas com contornos menos definidos em objetos menores sobre a mesa, como livros e teclado, consistente com seu AbsRel mais alto nessa sequência (Tabela II). Em *freiburg2_desk*, o VDA obtém a melhor acurácia dos três, com boa preservação das estruturas finas da planta na cena. O ChronoDepth tem maior dificuldade nessa sequência, com separação de profundidade mais fraca entre os objetos da mesa e o fundo, refletida em seus menores AbsRel e δ_1 . Em *freiburg3_office*, o VDA alcança o melhor resultado entre as nove combinações modelo-sequência do estudo, com boa preservação da estrutura fina da planta ao fundo. O ChronoDepth, apesar de registrar aqui seu menor TAE nas sequências do TUM, tem a menor acurácia geométrica, com transição mais suave entre os objetos da mesa e o plano de fundo.

No vídeo do Bumba Meu Boi, domínio noturno com iluminação artificial e multidão em movimento, os três modelos preservam razoavelmente a silhueta da dançarina em primeiro plano. O ChronoDepth apresenta menos *flickering* perceptível entre quadros, consistente com seu menor TAE médio (Tabela I), mas a delimitação de bordas finas, como os adereços na mão da dançarina, é mais nítida no VDA e no DepthCrafter. Esse padrão, ChronoDepth mais estável temporalmente e menos preciso geometricamente, se repete nas quatro sequências.

C. Discussão

Um resultado que diverge do artigo original é a proximidade entre VDA e DepthCrafter no TUM RGB-D. Em KITTI, Sintel, ScanNet, NYUv2 e Bonn, o artigo original mostra o VDA superando o DepthCrafter por margem clara. Dois fatores explicam a diferença: a variante ViT-S usada neste estudo é




Fig. 3. Comparação qualitativa entre VDA, DepthCrafter e ChronoDepth nas quatro sequências avaliadas: freiburg1_desk, freiburg2_desk, freiburg3_office e Bumba Meu Boi Raízes do Maranhão.

mais leve e menos expressiva que a ViT-L reportada como modelo principal no artigo; e o TUM RGB-D não pertence aos conjuntos de treinamento ou avaliação de nenhum dos dois modelos, reforçando o caráter zero-shot desta avaliação.

O trade-off entre acurácia geométrica e suavidade temporal aparece com consistência nos domínios quantitativo e qualitativo. Cenas com requisito de fidelidade geométrica, como reconstrução 3D, favorecem VDA ou DepthCrafter. Aplicações sensíveis ao *flickering* visual podem se beneficiar da maior consistência temporal do ChronoDepth.

D. Limitações

Este estudo avalia apenas a variante ViT-S do VDA, mais leve e menos expressiva que a ViT-L reportada como modelo principal no artigo original. A avaliação quantitativa no TUM RGB-D cobre três sequências de 110 quadros cada, seguindo o protocolo do DepthCrafter [3]; sequências mais longas ou com movimento de câmera mais acentuado poderiam expor diferenças não capturadas neste recorte. A avaliação no Bumba Meu Boi é inteiramente qualitativa, dada a ausência de profundidade de referência para esse domínio.

V. CONCLUSÃO E TRABALHOS FUTUROS

Este trabalho reproduziu a formulação matemática, a arquitetura e a estratégia de inferência do Video Depth Anything e avaliou o modelo em regime zero-shot em dados fora do domínio de treinamento original: TUM RGB-D, com profundidade de sensor real para comparação quantitativa, e vídeo de manifestação cultural maranhense como estudo de caso qualitativo. VDA e DepthCrafter apresentam desempenho

geométrico equivalente nas três sequências do TUM RGB-D. O ChronoDepth obtém maior consistência temporal ao custo de menor acurácia geométrica, trade-off que se mantém nos domínios quantitativo e qualitativo.

Trabalhos futuros podem avaliar a variante ViT-L do VDA sob o mesmo protocolo, estender a análise do Bumba Meu Boi com profundidade de referência obtida por outros meios e incluir o DepthAnyVideo na comparação dado acesso a hardware com maior memória de GPU.

AGRADECIMENTOS

Os autores agradecem à disciplina de Processamento Digital de Imagens da Universidade Federal do Maranhão pela orientação neste trabalho e pelo acesso aos recursos que tornaram possível a reprodução experimental.

REFERÊNCIAS

- [1] S. Chen *et al.*, “Video Depth Anything: Consistent Depth Estimation for Super-Long Videos,” *arXiv preprint arXiv:2501.12375*, 2025.
- [2] L. Yang *et al.*, “Depth Anything V2,” *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.
- [3] W. Hu *et al.*, “DepthCrafter: Generating Consistent Long Depth Sequences for Open-world Videos,” *arXiv preprint arXiv:2409.02095*, 2024.
- [4] J. Shao *et al.*, “Learning Temporally Consistent Video Depth from Video Diffusion Priors,” *arXiv preprint arXiv:2406.01493*, 2024.
- [5] H. Yang *et al.*, “Depth Any Video with Scalable Synthetic Data,” *arXiv preprint arXiv:2410.10815*, 2024.
- [6] Y. Wang *et al.*, “Neural Video Depth Stabilizer,” *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023.
- [7] R. Ranftl *et al.*, “Towards Robust Monocular Depth Estimation: Mixing Datasets for Zero-shot Cross-dataset Transfer,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2020.

- [8] M. Oquab *et al.*, “DINOv2: Learning Robust Visual Features without Supervision,” *arXiv preprint arXiv:2304.07193*, 2023.
- [9] A. Blattmann *et al.*, “Stable Video Diffusion: Scaling Latent Video Diffusion Models to Large Datasets,” *arXiv preprint arXiv:2311.15127*, 2023.
- [10] F. Perazzi *et al.*, “A Benchmark Dataset and Evaluation Methodology for Video Object Segmentation,” *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [11] J. Sturm *et al.*, “A Benchmark for the Evaluation of RGB-D SLAM Systems,” *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2012.